

Modèles mathématiques utilisés pour notre Dataset sur la Césarienne Infantile

1. Régression Logistique — le modèle de référence

Ce modèle constitue le point de départ naturel pour un problème de **classification binaire** (urgence vs normale). Il évalue la probabilité qu'une observation appartienne à la classe "urgence" via la fonction sigmoïde :

$$P(Y = 1 | \mathbf{x}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p)}}$$

Ici, $\mathbf{x}$ représente le vecteur des variables (éducation, poids, CPN...), et les β_i sont les coefficients obtenus par **maximisation de la vraisemblance** (MLE). La décision est prise : si $P > 0.5$, alors c'est "urgence".

2. Random Forest — le modèle ensembliste

Ce modèle construit B arbres de décision indépendants, chacun étant entraîné sur un sous-échantillon bootstrap du jeu de données et un sous-ensemble aléatoire de variables. La prédiction finale s'effectue par un **vote majoritaire** :

$$\hat{y} = \text{majorité}\{h_b(\mathbf{x})\}_{b=1}^B$$

Chaque arbre h_b segmente l'espace des caractéristiques en minimisant l'**impureté de Gini** :

$$G = 1 - \sum_k p_k^2$$

3. XGBoost — le modèle sélectionné (meilleur AUC)

Cet algorithme de **Gradient Boosting** construit les arbres **séquentiellement**, chaque nouvel arbre corrigeant les erreurs du précédent. La fonction objective optimisée est :

$$\mathcal{L}(\phi) = \sum_{i=1}^n \ell(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)) + \Omega(f_t)$$

Le terme de régularisation est donné par :

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

où T est le nombre de feuilles, w_j les poids correspondants, et γ et λ sont des hyperparamètres de régularisation. À chaque itération, XGBoost résout ce problème en utilisant une **approximation de Taylor du second ordre** de la perte, garantissant ainsi une précision et rapidité optimales.

Base théorique et justification des choix

Ces modèles s'appuient sur la **théorie statistique de l'apprentissage supervisé** (Vapnik, 1995) et le **cadre du boosting** (Friedman, 2001). Trois raisons ont motivé le choix de XGBoost comme modèle final :

- **Nature des données** : le jeu de données est tabulaire et hétérogène (variables ordinales, nominales, numériques), idéal pour les arbres de gradient boosté, qui montrent une supériorité empirique dans ce cas.
- **Déséquilibre de classes** : le paramètre scale-pos-weight = 34 prend en compte le ratio 34:1, pénalisant davantage les erreurs sur la classe minoritaire (urgence).
- **Robustesse aux interactions** : les arbres peuvent capturer automatiquement les **interactions non-linéaires** entre variables (par exemple : femme rurale + non éduquée + aucune CPN → risque combiné), ce qui n'est pas possible avec la régression logistique sans intervention manuelle sur les caractéristiques.

Ce qui rend ce travail unique

Plusieurs éléments distinguent ce projet d'une modélisation conventionnelle :

Concernant la méthodologie, le déséquilibre extrême de 34:1 est abordé à deux niveaux. D'une part, le SMOTE est appliqué au jeu d'entraînement pour rééquilibrer la distribution, et d'autre part, scale_pos_weight dans XGBoost pénalise les faux négatifs (négliger une urgence est médicalement plus problématique qu'une fausse alerte). Le **F1-score** sur la classe urgence a été choisi comme métrique d'optimisation, plutôt que l'accuracy — car un modèle naïf qui prédit "toujours normale" pourrait afficher 97% d'accuracy sans aucune utilité clinique.

Concernant les données, le jeu de données couvre **21 pays d'Afrique subsaharienne** avec 238 281 observations provenant des **Enquêtes Démographiques et de Santé (DHS)**, considérées comme la référence mondiale en matière de santé maternelle. La variable country est intégrée comme prédicteur, permettant au modèle d'apprendre les **disparités géographiques** (ex. : Rwanda à 8,9% vs Madagascar à 1,1%).

Concernant l'impact, le modèle prédit une urgence obstétricale **avant** qu'elle ne se produise, en se basant sur des informations disponibles dès la consultation prénatale. Dans des contextes où l'accès aux services médicaux est limité, cette anticipation peut réellement

sauver des vies. Cela transforme un exercice de machine learning en un **outil de santé publique**.